

Détecteur de Messages Toxiques

Projet d'IA Appliquée au Traitement du Langage

Organisation structurée, choix technologiques agiles et plan de travail optimisé pour un groupe de 6 étudiants.

La Problématique

Pourquoi automatiser la modération sémantique de contenus à l'aide d'outils d'intelligence artificielle légers et accessibles ?

| Objectifs Globaux

1. Algorithmes NLP & IA

Créer un classifieur de texte capable de catégoriser les messages négatifs ou toxiques (insultes, menaces, négativité).


Comparer une approche statistique simple à une intégration d'un modèle pré-entraîné plus performant (SOTA).

2. Interface & Intégration

Fournir une application web épurée et interactive pour permettre aux utilisateurs de tester des phrases à la volée.

Concevoir une architecture découplée (API Backend et Client Frontend) facilitant le travail collaboratif à 6.

| Pourquoi ce projet ?



Une approche par étapes

L'IA et le NLP (Natural Language Processing) paraissent complexes, mais en découpant le projet, il devient extrêmement accessible et formateur.

Plutôt que d'entraîner d'immenses modèles à partir de zéro, nous exploitons des technologies open-source matures pour créer un produit fonctionnel de bout en bout.

| Le Pipeline NLP

Prétraitement du texte

Avant d'envoyer un message brut à un modèle d'IA classique, il doit être nettoyé et structuré de manière rigoureuse :

- **Nettoyage** : Suppression de la ponctuation, des émojis et conversion en minuscules.
- **Filtrage sémantique** : Élimination des "stop words" (les mots de liaison sans valeur informative).
- **Lemmatisation** : Réduction des termes à leur racine (ex : "pensait" devient "penser") pour unifier le vocabulaire.



Les Modèles d'IA


Approche Hybride

Nous implémentons deux approches pour comparer leur efficacité : les modèles classiques statistiques et les modèles de Deep Learning avancés.

La probabilité d'une classification binaire standard est calculée à l'aide de la fonction sigmoïde suivante :

$$P(y = 1 | x) = \frac{1}{1 + e^{-z}}$$

Feature Maps



Feature Extraction

| Architecture Projet



API Backend (FastAPI)

Un serveur web léger développé en Python qui reçoit les requêtes textuelles, applique les modèles d'IA et renvoie les scores de toxicité.



Interface (Streamlit)

Une application web interactive simple d'utilisation pour le test en temps réel, le dépôt de fichiers et la visualisation des graphiques.



Serveur de Modèles

Intégration transparente de Scikit-Learn (local) et appel de modèles avancés hébergés sur la plateforme d'API Hugging Face.

| Objectifs Métriques

94%

F1-Score visé en classification

Évaluation des Performances

Le taux de précision est crucial pour une bonne modération de contenu. Nous visons un F1-Score élevé sur notre corpus de test (Kaggle dataset).

Nous cherchons également à minimiser la latence (temps de réponse inférieur à 100ms) pour garantir une analyse fluide au fil de la saisie utilisateur.

| Fonctionnalités Clés

-  **Analyse interactive en direct** : Saisie d'un texte par l'utilisateur avec retour instantané du niveau de toxicité estimé.
-  **Analyse de fichiers groupés** : Dépôt d'un fichier CSV pour analyser une liste de commentaires et exporter les résultats.
-  **Visualisation analytique** : Graphiques montrant la distribution des commentaires toxiques et non-toxiques.
-  **Seuil de détection ajustable** : Curseur permettant de modifier la sensibilité de l'algorithme de détection.

Répartition des 6 Rôles

Membre d'équipe	Rôle principal	Livrables techniques attendus
Étudiant 1	Chef de projet & UI Dev (Streamlit)	Interface Streamlit, graphiques interactifs et coordination d'équipe.
Étudiant 2	Data Engineer (NLP Pipeline)	Recherche de datasets, scripts de prétraitement sémantique (NLTK).
Étudiant 3	ML Engineer (Modèles classiques)	Entraînement des modèles classiques (Scikit-Learn : Naive Bayes, SVM).
Étudiant 4	DL Engineer (Modèles avancés)	Intégration de Transformers pré-entraînés (Hugging Face / BERT).
Étudiant 5	Backend API Developer (FastAPI)	Développement de l'API REST exposant les modèles de classification.
Étudiant 6	QA, MLOps & Évaluation	Tests de robustesse, Dockerisation des services et matrice d'évaluation.

| Plan de Route (4 sem.)




Des Questions ?

Nous vous remercions pour votre écoute.

Ce projet allie de façon équilibrée l'ingénierie des données, la modélisation IA et le développement web.

Module IA • Groupe d'Étudiants (6 personnes)

| Image Sources




https://files.realpython.com/media/How-to-Use-SpaCy-for-Natural-Language-Processing-in-Python_Watermarked_1.b363fc084a80.jpg

Source: realpython.com



<https://static.vecteezy.com/system/resources/thumbnails/070/071/627/small/computer-screen-displaying-code-on-desk-with-plant-and-coffee-cup-technology-and-modern-workspace-free-photo.jpg>

Source: www.vecteezy.com



https://media.geeksforgeeks.org/wp-content/uploads/20260217113409515144/working_of_cnn_.webp

Source: www.geeksforgeeks.org